

	UNIVERSIDAD NACIONAL DE SAN AGUSTÍN FACULTAD DE INGENIERÍA DE PRODUCCIÓN Y SERVICIOS ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMA	
Formato: Guía de Práctica de Laboratorio / Talleres / Centros de Simulación		
Aprobación: 2022/03/01	Código: GUIA-PRLE-001	Página: 1

INFORME DE LABORATORIO

INFORMACIÓN BÁSICA					
ASIGNATURA:	TECNOLOGÍAS DE INFORMACIÓN				
TÍTULO DE LA PRÁCTICA:	Agentes de Inteligencia Artificial (II)				
NÚMERO DE PRÁCTICA:	10	AÑO LECTIVO:	2026	NRO. SEMESTRE:	2026A
FECHA DE PRESENTACIÓN	08/05/2026	HORA DE PRESENTACIÓN			
INTEGRANTE (s): GRUPO N°3 • Arce Valencia, Anderson Lino • Caracela Chalco, Anthony Jeffry • Camani Chambi, Ronald Rodrigo • Condori Caira, Antony Beltran • Sucle Suca, Michael Benjamín				NOTA:	
DOCENTE(s): Mg. Maribel Molina Barriga					

SOLUCIÓN Y RESULTADOS

Ejercicio 1. Caso Empresarial


La empresa "Finanzas Inteligentes SAC" recibe diariamente reportes financieros de distintas sucursales. Se requiere construir un agente IA con memoria que pueda analizar reportes mensuales y generar automáticamente resúmenes ejecutivos.

Actividades


- 1. Diseñar arquitectura.
- 2. Implementar memoria: `src/memoria.py` + archivo persistente `memoria/memoria\_financiera.json`.
- 3. Crear prompts especializados: `src/prompts.py`: analista/extracción, resumen ejecutivo, juez auditor
- 4. Analizar tres reportes.
- 5. Generar resúmenes.
- 6. Evaluar resultados.

Entregable

- Stack:LangChain 1.3 + Gemini (`gemini-2.5-flash-lite`) + LangSmith
- Arquitectura:



- Flujo por reporte financiero



- Código o configuración.

None

```
src/
├── config.py          # .env + construcción del LLM Gemini
├── memoria.py         # Memoria de corto y largo plazo
├── prompts.py         # Prompts especializados
├── agente.py          # Agente: extracción + resumen
├── evaluacion.py      # Evaluación: checks exactos + LLM-juez (actividad 6)
├── data/reportes/     # 3 reportes mensuales (actividad 4)
├── resúmenes/         # Salida: resúmenes ejecutivos + evaluación (actividad 5)
├── memoria/           # Memoria persistente del agente (JSON, se autogenera)
└── main.py            # Orquestador
```

- Repositorio: <https://github.com/ronaldcamani/Finanzas-IA.git>

Resultados obtenidos.	Resumen generado del mes de marzo
---	---

Procesando: 2026-01_enero.txt

Matrices extraídas: Ingresos \$/ 890,000, utilidad \$/ 339,000

Resumen guardado en: resúmenes/resumen_2026-01_enero.md

Evaluando...

Cifras correctas: 100% | Rúbrica LLM: {'fidelidad': 5, 'completitud': 5, 'uso_de_memoria': 5, 'accionabilidad': 5, 'comentario': 'El resumen es excelente en fidelidad y completitud, capturando todos los datos clave y observaciones. Las recomendaciones son muy concretas y útiles, abordando directamente los puntos críticos del reporte.'}

Procesando: 2026-02_febrero.txt

Matrices extraídas: Ingresos \$/ 921,000, utilidad \$/ 352,000

Resumen guardado en: resúmenes/resumen_2026-02_febrero.md

Evaluando...

Cifras correctas: 100% | Rúbrica LLM: {'fidelidad': 5, 'completitud': 5, 'uso_de_memoria': 5, 'accionabilidad': 5, 'comentario': 'El resumen es excelente en fidelidad, completitud y análisis comparativo. Las recomendaciones son claras y directamente aplicables a los puntos críticos identificados.'}

Procesando: 2026-03_marzo.txt

Matrices extraídas: Ingresos \$/ 958,000, utilidad \$/ 404,000

Resumen guardado en: resúmenes/resumen_2026-03_marzo.md

Evaluando...

Cifras correctas: 100% | Rúbrica LLM: {'fidelidad': 5, 'completitud': 5, 'uso_de_memoria': 5, 'accionabilidad': 5, 'comentario': 'El resumen es excelente en su fidelidad y completitud, presentando todos los datos y análisis clave con precisión. El uso de la memoria para comparaciones es excelente y las recomendaciones son concretas y directamente aplicables.'}

Informe de evaluación: /home/roaof/Documents/Finanzas-IA/resúmenes/evaluacion.md

Revisa los Tráns en: [https://smith.langchain.com \(Proyecto 'Finanzas-IA'\)](https://smith.langchain.com (Proyecto 'Finanzas-IA'))

95.498s 19:33

Resumen Ejecutivo - Marzo 2026

resumen_2026-03_marzo.md

Resultados del mes

En marzo de 2026, Finanzas Inteligentes S&C alcanzó ingresos totales de \$/ 958,000 y gastos operativos de \$/ 554,000, resultando en una utilidad operativa de \$/ 404,000. El margen operativo mejoró significativamente a 42.2%.

Desglose por sucursal

Lima generó \$/ 498,000 en ingresos, mostrando una leve caída respecto a febrero debido al fin de la campaña de verano. Arequipa experimentó una fuerte recuperación, alcanzando \$/ 279,000, impulsada por la incorporación de nuevos analistas. Cusco continuó su tendencia de crecimiento, suando \$/ 181,000.

Comparación con meses anteriores

Los ingresos totales aumentaron un 3.91% respecto a febrero (\$/ 921,000). Los gastos operativos disminuyeron un 2.64% (\$/ 569,000), destacando la reducción en provisiones por incobrables. La utilidad operativa se disparó un 14.77%. La more > 30 días se redujo notablemente en 0.7 pp, situándose en 3.9%, gracias al nuevo modelo de scoring. El número de clientes nuevos se incrementó en un 14.91%.

Riesgos y alertas

1. Caída temporal en Lima: La disminución de ingresos en Lima (-2.7% vs febrero) requiere atención, aunque se anticipa una recuperación con la nueva campaña "Crédito Escolar".
2. *Sostenibilidad del crecimiento en Arequipa y Cusco*: Es crucial mantener el impulso en estas sucursales tras su reciente recuperación y crecimiento.

Recomendaciones

1. Lanzar y optimizar la campaña "Crédito Escolar" en Lima: Asegurar una ejecución efectiva para compensar la caída de ingresos y mantener el dinamismo.
2. Consolidar la mejora en Arequipa y Cusco: Implementar estrategias para mantener la tendencia positiva en colocación y captación de clientes en ambas sucursales.
3. Analizar la reducción de provisiones: Evaluar si la disminución en provisiones por incobrables se debe a una mejora estructural en la calidad de la cartera o a factores temporales.

Evaluación de Reportes

Trazas del Agente finanzas-ia

Evaluación de resúmenes ejecutivos

evaluacion.md

Mes	Cifras presentes	Fidelidad	Completitud	Uso de memoria	Accionabilidad
2026-01_enero	100%	5/5	5/5	5/5	5/5
2026-02_febrero	100%	5/5	5/5	5/5	5/5
2026-03_marzo	100%	5/5	5/5	5/5	5/5

Comentarios del juez

- 2026-01_enero: El resumen es fiel y completo, reflejando todos los datos clave del reporte. La comparación con meses anteriores y las recomendaciones son adecuadas.
- 2026-02_febrero: El resumen es excelente, fiel al reporte y cubre todos los puntos clave. Las comparaciones y recomendaciones son precisas y útiles.
- 2026-03_marzo: El resumen es excelente, fiel, completo y con comparaciones y recomendaciones muy útiles.

finanzas-ia

Tracing Evaluators Automations Insights Engine New

Default View Last 1 day Threads Tables Runs Input Search input content

	Name	Input	Output	Error	Start Time	Latency	Dataset	Annotation	Tokens	Cost
	juez_evaluador	Enero 2026 Ingresos S...	"Enero ('fidelidad': 5, 'to...		7/5/2026, 7:30...	5.60s			3,590	\$0.001492
	RunnableWorkflowMessageL...	Enero 2026 Ingresos S...	## Resumen Ejecutivo ...		7/5/2026, 7:39...	14.41s			6,749	\$0.002639
	extractor_merikas	REPORTE FINANCIERO ...	"Enero ('meses": "Marzo 2...		7/5/2026, 7:39...	24.50s			2,391	\$0.0036427
	juez_evaluador	Enero 2026 Ingresos S...	"Enero ('fidelidad': 5, 'to...		7/5/2026, 7:39...	7.78s			1,184	\$0.004597
	RunnableWorkflowMessageL...	Enero 2026 Ingresos S...	## Resumen Ejecutivo ...		7/5/2026, 7:39...	14.94s			5,482	\$0.003695
	extractor_merikas	REPORTE FINANCIERO ...	"Enero ('meses": "Febrero ...		7/5/2026, 7:39...	4.10s			1,701	\$0.0024551
	juez_evaluador	sin meses anteriores es...	"Enero ('fidelidad': 5, 'to...		7/5/2026, 7:39...	4.91s			2,319	\$0.0030255
	RunnableWorkflowMessageL...	sin meses anteriores es...	## Resumen Ejecutivo ...		7/5/2026, 7:39...	9.21s			2,924	\$0.0056424
	extractor_merikas	REPORTE FINANCIERO ...	"Enero ('meses": "Enero 20...		7/5/2026, 7:39...	4.59s			1,768	\$0.0029884

- Output de reporte de LLM como Juez evaluador

juez_evaluador ID

Feedback Input Output Attributes

Input

Output

Fields

output

json

{
 "fidelidad": 5,
 "completitud": 5,
 "uso_de_memoria": 5,
 "accionabilidad": 5,
 "comentario": "El resumen es excelente, fiel, completo y con comparaciones y recomendaciones muy útiles."
}

Ejercicio 2. Caso Empresarial

La corporación multinacional "RetailNova Group" opera más de 300 tiendas físicas y comercio electrónico en Latinoamérica.

La organización enfrenta problemas simultáneos:

- Ruptura de stock.
- Incremento de costos logísticos.
- Retrasos en distribución.
- Baja precisión de pronósticos.

La dirección ejecutiva solicita desarrollar una solución basada en agentes IA colaborativos para optimizar la cadena de suministro.

Actividades

Fase 1: Diagnóstico

1. Analizar procesos actuales.

Dado el contexto de la empresa, podemos deducir las siguientes ineficiencias en sus procesos actuales:

- Gestión de Inventarios: La reposición de productos no está sincronizada entre el comercio electrónico y las más de 300 tiendas físicas. Esto genera la actual ruptura de stock.
- Gestión de Distribución: Los retrasos en la distribución indican una falta de visibilidad en tiempo real de la flota y rutas ineficientes.
- Planificación de la Demanda: La baja precisión de pronósticos sugiere que la empresa se basa en modelos históricos estáticos sin considerar variables externas en tiempo real (tendencias, estacionalidad).
- Gestión de Costos: El incremento de costos logísticos es una consecuencia directa de envíos de emergencia por quiebres de stock y rutas mal planificadas.

2. Identificar fuentes de datos.

Para que los agentes de IA puedan operar mediante recuperación aumentada (RAG) y llamadas a herramientas (Tool Calling), necesitarán acceso a las siguientes fuentes:

- Sistemas ERP (Enterprise Resource Planning): Para niveles de inventario en tiempo real.

- Sistemas POS (Point of Sale): Datos de ventas diarias de las más de 300 tiendas físicas.
- Plataforma de E-commerce: Métricas de tráfico, carritos abandonados y ventas online.
- Sistemas WMS (Warehouse Management System) y TMS (Transport Management System): Para el seguimiento de despachos y gestión de almacenes.
- Bases de Datos Externas: APIs de clima, calendarios de festividades locales y tendencias de mercado.

3. Definir KPIs.

Problema a resolver	KPI Propuesto	Descripción
Ruptura de stock	Fill Rate (Tasa de cumplimiento)	Porcentaje de demanda de clientes que se satisface con el inventario disponible.
Baja precisión de pronósticos	MAPE (Error Porcentual Absoluto Medio)	Mide la precisión de las predicciones de demanda del agente de pronósticos.
Retrasos en distribución	OTIF (On Time In Full)	Porcentaje de pedidos entregados a tiempo y completos.
Incremento de costos logísticos	Costo Logístico por Unidad Vendida	Relación entre los gastos de transporte/almacenamiento y los productos vendidos.

Fase 2: Diseño Multiagente

4. Diseñar:

Agente Pronósticos:

- Rol: Analista de Demanda.
- Herramientas: Modelos de Machine Learning para series temporales, acceso a histórico de ventas y APIs de tendencias externas.
- Función: Predecir la demanda semanal por SKU y por sucursal, mitigando la baja precisión actual.

Agente Inventarios:

- Rol: Controlador de Stock.
- Herramientas: Acceso al ERP y base de datos de los 300 puntos de venta.
- Función: Monitorear los niveles de stock en tiempo real y emitir alertas tempranas antes de que ocurra una ruptura de stock.

Agente Logística:

- Rol: Optimizador de Cadena de Suministro.
- Herramientas: Integración con WMS, TMS y APIs de enrutamiento y tráfico.
- Función: Asignar unidades desde los centros de distribución hacia las tiendas físicas minimizando los costos logísticos y previniendo retrasos.



Agente Ejecutivo:

- Rol: Coordinador General y Soporte a Decisiones.
- Herramientas: Herramientas de generación de reportes y envío de alertas (ej. Email/Slack).
- Función: Recopilar las predicciones, estados de inventario y planes logísticos para generar un resumen ejecutivo con acciones recomendadas para la gerencia humana.

5. Diseñar interacciones.

El flujo de comunicación entre los agentes debe ser secuencial e iterativo:

1. Inicio del Ciclo: El Agente Pronósticos analiza los datos de ventas recientes y proyecta la demanda para los próximos 15 días. Envía este reporte al Agente de Inventarios.
2. Validación de Stock: El Agente Inventarios cruza la proyección de demanda con el stock actual en los almacenes y tiendas físicas. Identifica qué tiendas están en riesgo de quiebre de stock y envía una lista de necesidades al Agente Logístico.
3. Planificación de Rutas: El Agente Logística recibe las necesidades de abastecimiento, verifica la disponibilidad de transporte y planifica las rutas más económicas y rápidas para evitar retrasos. Envía el plan de costos y tiempos al Agente Ejecutivo.
4. Consolidación Final: El Agente Ejecutivo recibe la información de los tres agentes anteriores. Si los costos logísticos propuestos superan un umbral predefinido, puede solicitar al Agente Logístico que recalcule la ruta. Finalmente, aprueba el plan operativo y genera un "Dashboard Ejecutivo" o reporte final para la dirección.



Fase 3: Implementación

Todo el informe y capturas sobre el proceso de la implementación a detalle se encuentra en :

Click aquí - [Proceso de implementación](#)

Resultado:

Resultados de la Fase 3: Implementación

Final Result

Dashboard Ejecutivo: Operación Shop de Invierno Q1 2026

Resumen de APIs Estratégicas (Consolidadas Q1)

Este tablero sintetiza la demanda proyectada, la estrategia de inventario dinámica y la viabilidad logística para las 300 tiendas.

Resumen de Volumen y Demanda

API	Valor Objetivo	Impacto vs Q1 2025	Observación
Unidades Totales Demandadas	2,897,588 uds	+12.8%	Impulsado por crecimiento Latam y Omnicanalidad.
Stock de Seguridad (SS)	512,888 uds	+14.2%	Índice promedio estable en 155.86.
Fill Rate Objetivo	> 98%	N/A	Meta de nivel de servicio para evitar rupturas.
MRP (Error de Pronóstico)	4.2%	↓ (Optimizado)	Modelo robusto garantiza alta precisión.

Gestión de Inventario y Seguridad

API	Valor Consolidado	Estrategia Aplicada	Ahorro/Costo
Total Unidades Requeridas	3,274,625 uds	Demanda + Stock de Seguridad	Inversión Total de Stock.
Stock de Seguridad (SS)	512,888 uds	Dinámico Mensual (155 vs 154.82 22.2%)	4886 uds vs regla fije 15k.
Cobertura de Inventario	3.8 - 4.8 Semanas	Revisión Continua (S, O)	Optimización de flujo de caja.
Punto de Reorden (ROP)	Variable por Reg	Ajuste automático via ERP	Prevención rupturas en pico de julio.

Eficiencia Logística y Costos

API	Target	Riesgo Actual	Acción de Mitigación
OTIF Proveedores Tier 1	> 95%	Medio	Cláusulas de flexibilidad (+20% vol.).
Cantidad de Recepción DC	5000 unidades	ALTO (22K util)	Split loading estratégico Sem 14-15.
Ahorro Logístico (Sourcing)	Tier 1 Latam (3 sem)	Bajo	Reducción de lead time vs Importación.
Costo Abono/Contratista	\$0.35	Medio	Letras USD ajustadas a capacidad.

CONCLUSIONES ESTRATÉGICAS DE LA CAMPAÑA DE INVIERNO

Tras analizar los reportes de Demanda, Inventarios y Logística, determino lo siguiente:

- Optimización Financiera del Stock: Se ha rechazado la regla plana del 15k de stock de seguridad. La adopción de un SS Dinámico permite reducir costos en julio y agosto, pero incrementa la protección en septiembre (22.2%), blindando la operación contra la incertidumbre climática y asegurando el éxito de la liquidación final.
- Viabilidad de la Operación (Tier 2): Existe un quiebre crítico en la ventana de pedido de Calzado y Bases Monitor. Al haber pasado la Semana 19, la operación enfrenta un riesgo de desabastecimiento de 2-3 semanas. La estrategia de Air Freight (flote aéreo) para el 30% del volumen es costosa (150k utilidades), pero indispensable para no perder ventas en el pico de temporada.
- Estado Operativo en DC: El Puntó inicial de 2.38 de unidades satisface el Centro de Distribución al 92% de su capacidad. No hay margen de error. Cualquier retraso en la recepción escalada generará cuellos de botella que impactarán directamente al Fill Rate en tienda.
- Reactividad Comercial: El modelo de "Pull-Based" con reposiciones algorítmicas semanales y transferencias inter-tienda dinámicas permite que RetailNova reaccione en menos a variaciones de demanda local, minimizando el ROP Inventory.

Fase 4: Evaluación

9. Analizar resultados.

3. DICTAMEN FINAL DE OPERACIONES

ESTADO: APROBADO CON CONDICIONES

La operación es viable y rentable, siempre y cuando se ejecuten las siguientes acciones correctivas en las próximas 72 horas:

Acciones Obligatorias para Ejecución Inmediata:

- [URGENTE] Confirmar la emisión de la orden de Air Freight para el 30% de Calzado/Técnicos para cubrir el gap de la Semana 14.
- [URGENTE] Validar el calendario de Appointment Slots en el DC para las semanas 21-25 para evitar colapsos en la recepción.
- [ESTRATÉGICO] Implementar el Dashboard de Sell-through por Cluster (Frio/templado) para ajustar los ROP de agosto y septiembre en tiempo real.
- [CONTRACTUAL] Asegurar que todos los contratos Tier 1 incluyan la cláusula de devolución del 15% si el sell-through es <70% al 15 de septiembre.

Costo Estimado de Mitigación de Riesgo: Incremento del 35% en costo unitario del 30% del volumen de calzado (estimado como costo de oportunidad evitado).

El proceso tomó 10 minutos.

El primer uso tomo como 25 minutos, ya que estaba sacando datos de la web a través de serpa

Usa una buena cantidad de tokens pero aún hay suficiente para el uso de dos modelos de nvidia nim

type	llm_call_completed												
model	nvidia_nim/google/gemma-4-31b-it												
usage	6 fields <table> <tr> <td>total_tokens</td><td>9418</td></tr> <tr> <td>prompt_tokens</td><td>7948</td></tr> <tr> <td>reasoning_tokens</td><td>0</td></tr> <tr> <td>completion_tokens</td><td>1470</td></tr> <tr> <td>prompt_tokens_details</td><td>null</td></tr> <tr> <td>completion_tokens_details</td><td>7 fields</td></tr> </table>	total_tokens	9418	prompt_tokens	7948	reasoning_tokens	0	completion_tokens	1470	prompt_tokens_details	null	completion_tokens_details	7 fields
total_tokens	9418												
prompt_tokens	7948												
reasoning_tokens	0												
completion_tokens	1470												
prompt_tokens_details	null												
completion_tokens_details	7 fields												
call_id	7e9b6f2e-28a9-4bf9-b788-befeb6fbac8a												

Problemas:

- Hubo conflictos con el uso de algunos modelos como OPENAI Y Google Gemini , despues de varios intentos solo utilice modelos de NVIDIA que son gratuitos y muy intuitivos
- La mayoría de api's son de paga y crewai como usa nativamente OPENAI , genere conflictos con la configuración de otros modelos llm
- En mi caso hubo una vez que los servidores de nvidia no respondieron, entonces la caida del servicio es posible y toca reiniciar todo de nuevo

10. Medir beneficios.

- Tiene algunas herramientas útiles como creación de documentos en formato md, que da una mejor visualización que solo formato txt
- Sus respuestas son concisas e intuitivas
- Te da varias opciones de como quieres que sea la dinámica del flujo de trabajo.
- El sistema está altamente desacoplado. Si mañana el proyecto crece, puedes agregar un nuevo agente sin tener que reescribir el código de los demás agentes.
- **Crewia** tiene preferencia nativa por OpenAI, su integración con LiteLLM demuestra que la arquitectura es flexible y permite pivotar entre proveedores para optimizar costos de API sin cambiar la lógica del negocio.
- Como cada agente IA tiene un rol definido esto evita que haya alusiones o errores, en este caso la simulación se basa de la informacion de internet para obtener los datos y generar una prediccion,

11. Proponer mejoras.

Resiliencia ante Fallos : Con el objetivo de mitigar el riesgo de parálisis operativa por indisponibilidad de los servidores de NVIDIA, se propone la implementación de un protocolo de conmutación por error. Ante una latencia crítica o falta de respuesta del modelo primario, la arquitectura realizará una transición automática hacia un motor secundario (v.g., Gemini), garantizando la continuidad del flujo de trabajo y evitando la necesidad de reinicios manuales por parte del usuario.

Integración con datos en Tiempo Real: En lugar de depender únicamente de búsquedas web estáticas, la arquitectura podría conectarse a través de protocolos ligeros (como MQTT) a flujos de datos en vivo.

Entregable

- Arquitectura empresarial.
- Diseño multiagente.
- Evidencias.
- Dashboard ejecutivo.
- Conclusiones.

Recordar...! Entregable informe Técnico (5 páginas)

I. SOLUCIÓN DEL CUESTIONARIO

¿Cómo pueden los agentes multiagente transformar la toma de decisiones estratégicas en organizaciones complejas?

Los sistemas multiagente transforman la toma de decisiones estratégicas al integrar capacidades distribuidas de análisis, simulación y optimización en tiempo real. Cada agente especializado (inventarios, logística, pronósticos, ejecutivo) procesa su dominio de conocimiento y colabora con los demás mediante protocolos de comunicación, lo que permite generar una visión holística de la organización. Esta arquitectura reduce los silos de información, acelera el tiempo de respuesta ante cambios del mercado y facilita la exploración de escenarios alternativos. Además, al combinar memoria de largo plazo con herramientas de recuperación de datos, los agentes pueden aprender de decisiones pasadas y ajustar sus recomendaciones, mejorando la precisión y consistencia de las estrategias formuladas.

¿Qué riesgos organizacionales surgirían si los agentes autónomos toman decisiones críticas sin mecanismos adecuados de gobernanza?

La ausencia de gobernanza en agentes autónomos expone a la organización a riesgos significativos, como la toma de decisiones sesgadas por datos incompletos o corruptos, la falta de trazabilidad en acciones críticas y la imposibilidad de auditar el razonamiento del agente. También se incrementa el peligro de acciones no alineadas con los objetivos estratégicos o con normativas legales y éticas, lo que puede derivar en sanciones, pérdida de reputación y conflictos internos. Sin mecanismos de supervisión humana, control de acceso y registros de auditoría, la organización pierde capacidad de intervención oportuna, y los errores se multiplican rápidamente al propagarse entre agentes interconectados, afectando la estabilidad operativa y la confianza de los stakeholders.

¿Considera que los agentes IA avanzados podrían reemplazar completamente a los analistas humanos en el futuro? Justifique técnica y éticamente.

Técnicamente, los agentes IA avanzados pueden automatizar tareas analíticas repetitivas, procesar grandes volúmenes de datos y generar resúmenes ejecutivos con alta eficiencia. Sin embargo, carecen de comprensión contextual profunda, intuición estratégica y capacidad para manejar ambigüedades o dilemas éticos no estructurados. Éticamente, el reemplazo completo eliminaría el juicio humano necesario para validar supuestos, interpretar resultados en marcos sociales y asumir responsabilidad final sobre las decisiones. Por ello, el escenario más viable es uno de colaboración aumentada, donde los agentes actúan como asistentes inteligentes que potencian las capacidades de los analistas, liberándolos de tareas operativas para que se concentren en actividades de alto valor añadido, supervisión y toma de decisiones con criterio humano.

II. CONCLUSIONES

- Los agentes multiagente requieren un diseño cuidadoso de roles, interacciones y protocolos de comunicación para evitar conflictos operativos y garantizar que las decisiones colectivas sean coherentes con los objetivos empresariales, lo que implica un trabajo interdisciplinario entre ingenieros, analistas de negocio y responsables de gobierno de datos.
- La implementación de memoria de corto y largo plazo en agentes IA es fundamental para mejorar la consistencia de los análisis y permitir el aprendizaje continuo, pero también introduce desafíos de almacenamiento, gestión de versiones y privacidad de la información sensible de la organización.
- La integración de RAG con agentes colaborativos reduce significativamente las alucinaciones y aumenta la precisión de las respuestas, siempre que las bases documentales estén actualizadas, bien estructuradas y cuenten con controles de calidad que garanticen la veracidad de las fuentes recuperadas.
- La gobernanza de agentes autónomos debe incluir mecanismos explícitos de supervisión humana, registros de auditoría, políticas de autorización y límites de acción, ya que estos componentes son tan críticos como el propio modelo de lenguaje para la adopción segura y confiable en entornos productivos.
- Los ejercicios prácticos con CrewAI y LangChain evidencian que la simulación de flujos de trabajo multiagente permite identificar cuellos de botella, redundancias y oportunidades de mejora antes de la implementación real, convirtiendo a estas herramientas en aliadas estratégicas para la innovación en la cadena de suministro y la inteligencia de negocios.

REFERENCIAS Y BIBLIOGRAFÍA

Bibliografía:

- Russell, S. & Norvig, P. (2021).
- Wooldridge, M. (2021).
- Ng, A. (2024).
- Shapiro, S. (2024). AI Agents in Enterprise Systems.

Recursos web:

- LangChain Official Documentation <https://docs.langchain.com/oss/python/langchain/overview>
- CrewAI Official Documentation <https://docs.crewai.com/>
- AutoGen Documentation <https://microsoft.github.io/autogen/stable/>
- OpenAI Platform Documentation <https://developers.openai.com/api/docs>

